

阚海

大模型应用 / Agent 算法 / 搜索推荐方向

13046859853 | 2025282050209@whu.edu.cn

教育背景

武汉大学 | 测绘工程 | 硕士

2025.09 - 2027.06

- 研究方向：基于 YOLO 的车载影像敏感信息识别；基于 GAN 的地理数据多尺度更新
- 课程：人工智能与机器学习、深度学习与大模型

中南大学 | 测绘工程 | 学士

2021.09 - 2025.06

- 研究方向：基于三维高斯泼溅的无人机影像三维重建
- 课程：Python、C++、数据结构、科学计算与 MATLAB

实习经历

阿里巴巴 | 【部门待确认】 大模型应用 / 算法实习生【岗位待确认】

【起止时间待确认】

EduBot 多 Agent 路由与任务编排 | 核心开发 / 链路审计

- 参与教育大模型多 Agent 控制链建设，将 Scene 直达、Main ToolCall Handoff、active sticky 与 SubAgent Handback 收敛到统一 Router；明确 Gate advice 与 Router effect 边界，支撑 Main / 专业 Agent 跨轮连续承接。
- 设计“高精度规则优先 + 单 token 轻量模型 + 双阈值 margin”连续性判定，结合请求级实验配置快照与 fail-open 降级，在时延、误切换风险和任务连续性之间取平衡。
- 建设 active / paused Task、Topic、Owner、LGI 与 revision/CAS 状态链，完善 PREEMPT / RESUME、ToolCall-ToolResult 闭合及 Chat/Live/SSE 交付语义；梳理并发重叠、迟到结果与游标回退风险。
- 完成线上 on 桶 163 个多轮 Session / 902 请求全链路对账与 18 个 Session 语义审计，验证终态 898/902 正常并定位恢复规则双向失准、LGI 非零回退与 conflict 无重评等问题；单日实验初步观察到 Session 转讲万物率 +14.9pp、单轮退出率 -4.7pp、放弃率 -2.5pp (1128/197 Sessions，真实干预率 6.7%，需结合小样本口径解释)。

教育对话主动服务 | 算法与工程设计

- 设计“上一轮异步 prepare、下一轮实时 confirm”的两阶段主动服务链：dialogue_turn Event 触发 L0-L4 Graph 生成 pending steering，下一轮 Delivery Gate 基于最新 Query 再判 fit，仅在 Prompt 开关开启且实际执行 Main 时注入。
- 构建 L0 状态重建、L1 规则准入/频控、L2 用户姿态感知、L3 Goal+Guidance 联合决策与确定性 post-correction、L4 暂存分发，覆盖危机/拒绝阻断、冷启动、通道 cooldown、结构校验与 quiet turn。
- 面向多 Worker / 多机房设计连接复用、Redis 水合、TTL、短锁与异步多写；识别非原子消费、candidate goal 跨 Worker 丢失及 200ms/400ms deadline 错配，给出 atomic claim、delivery token、lease 与 ACK 的演进方案。
- A/B 结果：On/Off 分别 16,238/15,889 Sessions，实际注入 417 Sessions (2.57%)；平均 Main 轮次 +0.480、多轮率 +1.91pp、深度对话率 +1.66pp、平均会话时长 +12.67 秒，均达到统计显著 ($p \leq 0.0096$)。

高途教育集团 | 用户研发部 | 算法研发组 大模型应用开发实习生

2026.02 - 2026.04

智能搜索对话系统 | 核心成员

- 参与 C 端主 App 搜索算法链路重构，覆盖 Query 标准化、实体证据收集、意图分类、动态检索路由、混合召回/重排和会话管理；将纯关键词、向量与 LLM 能力按成本和确定性分层。
- 建设 BERT 意图识别训练链路：融合约 1.4 万真实样本、实体标注与模板合成数据，使新增老师/课程等实体通过词典更新即可泛化；以类别权重、Focal Loss、Label Smoothing 改善长尾类和 hard case，并采用高置信本地模型、低置信轻量 LLM 回退。
- 重构上下文管理：近期轮次用 role-aware messages 保真，FactMemory 全量注入，EventSummary 通过 RAG 按需召回；结合 tiktoken、轮次上限与超预算摘要控制上下文成本。

用户画像与长期记忆 | 负责人

- 从 0 到 1 设计离线画像/长期记忆 Pipeline，将多源行为统一为 HistoryEvent，经 session/天/周窗口生成 EventSummary，再增量抽取 FactMemory，并构建 L1 静态、L2 统计、L3 动态兴趣画像。
- 设计 FactMemory ADD/SKIP/MERGE/REPLACE 生命周期协议：规则前置减少不必要 LLM 调用，按 category+tag 合并并保留 inactive 演化历史、来源与时效；基于 SHA-256 Prompt 缓存、分类重试和 Token 分步追踪控制成本。
- 处理 40 万+搜索记录、322 万+课程行为、124 万+订单、562 万+社区互动等数据；课程内容关联覆盖率 98.7%，32 个固定记忆标签覆盖率 90%+，EventSummary 线程池并行实现约 4 倍加速。

多模态标签服务 | 负责人

- 负责教育图文/视频内容的兴趣与地域标签主链，统一图片压缩、视频均匀抽 20 帧、封面优先、16k 音频转写与多模态消息编排；地域标签按“目标受众所在地”而非普通地名抽取建模。
- 用候选标签、定义和正负样例约束多模态 LLM 输出，结合 JSON 解析、白名单映射、必含/排除词、优先级覆盖、去重和 Top3 限制，降低自创标签与过度泛化。
- 抽象 mock / OpenAI-compatible Provider，采用 ASR 懒加载、串行锁、单媒体失败不中断和本地文件支持，将算法主链从 HTTP/Apollo/回调基础设施中解耦为可运行 Demo。

相关技能

- 语言与工程：Python、SQL、C++（了解）、Linux、Git、Docker；Redis、HTTP/SSE、并发与分布式一致性基础
- 大模型应用：Agent / Handoff、Context Engineering、Long-term Memory、RAG、Prompt Engineering、Tool Calling、结构化输出
- 算法与框架：PyTorch、Transformer、BERT 意图分类、混合检索/BM25/向量检索、多模态 LLM、ASR；了解 SFT/PEFT 与强化学习
- 其他：CET-6；具备基础搜索推荐架构与 A/B 实验分析能力

论文及知识产权

- ISPRS 2026 Congress (TC II), Abstract Accepted：Image-Assisted Aerial LiDAR Completion with Morphology-Guided Gaussian Ellipsoids (Co-author；重建/数据 Pipeline、实验与可视化)
- 《地理空间信息》投稿（2025.11, Under Review）：《土地利用数据综合的改进型 Pix2Pix 深度学习模型》（Co-author；数据清洗、改进点梳理）
- 软件著作权（受理）：《基于深度学习的土地利用数据多尺度更新软件（MSLC-GAN）》（Co-author；数据清洗、软件封装）

投递前待确认：阿里部门、岗位名称与起止时间；论文/软著最新状态；内部数据与项目名是否允许对外披露。