

智能搜索对话系统

Query 标准化、实体证据、分层意图识别、动态检索路由与多层上下文

公司：高途教育集团 | 部门：用户研发部算法研发组 | 角色：核心成员 | 时间：2026.02 - 2026.04

30 秒版本 我参与了高途 C 端主 App 搜索链路重构。系统先做输入标准化和实体证据收集，再用高置信 BERT、低置信轻量 LLM 的分层意图识别决定是检索还是生成；检索侧按意图和实体构造动态 Filter，并用当前 Query、上下文和画像做乘法重排。我的重点还包括 BERT 训练链路和多层上下文：近期轮次保真、长期 FactMemory 注入、历史 EventSummary 按需 RAG，解决多轮指代与 token 成本。

一、项目背景

用户输入	难点	系统处理
白马老师有课吗	别名映射	词典证据 -> 老师实体 -> 课程查询
baima laoshi	拼音输入	实体词典生成拼音变体并最长匹配
考研数学怎么学	无显式实体的知识问题	低置信回退 LLM / 生成链
他有没有网课	跨轮指代	context entity + role-aware messages
AI 闪学在哪	产品功能模糊表达	证据 + 产品功能意图 -> 单结果入口

纯关键词无法覆盖别名、拼音和语义变体；纯向量召回容易混淆找老师/找课程；纯 LLM 每请求调用时延和成本过高。因此采用本地快速处理优先、证据驱动和按不确定性升级。

二、我的工作

- 参与六步算法主链重构：QueryProcessor -> EvidenceCollector -> Intent -> ResponseBuilder -> Retriever/LLM -> SessionManager。
- 负责 BERT 意图识别训练链路：真实样本、实体增强、模板×实体、同义词与多轮上下文增强；WeightedTrainer 支持类别权重、Focal Loss、Label Smoothing。
- 设计 BERT 高置信优先、轻量 LLM 低置信回退、规则仅演示兜底的分层架构，按文本/图片设置差异阈值。

- 负责上下文管理：把历史从普通字符串改为 role-aware messages，精确 token 计数，近期保真、超限摘要，并与用户画像/长期记忆联动。
- 参与基于意图和实体的动态 VectorDB Filter、当前/上下文/画像权重重排与检索/生成路由。

生产与 Demo 边界 技术文档来自对原项目算法主链的去基础设施化 Demo。生产服务还包含 Django、Apollo、Eureka、SkyWalking、数据库治理和上下游编排；Demo 可独立运行并自动降级，但不能把 Demo 本身说成完整生产服务。

三、整体链路

Raw Query

-> 全角转半角 -> 繁简转换 -> 实体词典驱动的拼音转汉字 -> 空白清理 -> 分词

-> Evidence: 精确匹配 -> token 匹配 -> 模糊/向量回退 -> 去重融合

-> Intent: BERT(高置信) -> 轻量 LLM(低置信) -> 演示规则兜底

-> ResponseBuilder: 实体 target/filter 萃取 + 只基于当前 Query 的意图覆盖

-> 检索类: 动态 Filter + 混合召回 + 乘法重排; 生成类: LLM 回答

-> SessionManager: 保存本轮并更新 context entity / 多层上下文

四、算法设计

4.1 证据收集

- 精确匹配使用多模式词典；文档采用 FlashText/Trie 思路，适合大量实体别名一次扫描。
- token 匹配降低置信度，模糊匹配只作回退；证据按 (type,value) 去重保留最高分。
- 实体证据在意图识别前产生，因为 BERT 本身不知道 ‘白马老师=褚佳麟’，外置知识能帮助分类。
- 推理时用与训练端一致的实体类型标记，最长匹配避免长短别名相互覆盖。

4.2 BERT 分层意图识别

层	条件	作用
本地 BERT	纯文本 confidence >=0.85；带图 >=0.90	10-50ms 量级，先处理确定样本
轻量 LLM	BERT 低置信或不可用	64-token JSON 意图；处理长尾/歧义
规则兜底	Demo 无 BERT/LLM	保持主链可运行；生产不依赖这一层

训练数据约包括 1.4 万真实用户标注、1.4 万实体打标版、5.4 万模板×实体合成和约 1.9 万均衡合并版。核心不是死记实体名，而是学习“实体类型 + 句式 -> 意图”，新增实体只需更新词典即可泛化。

4.3 类别不均衡与 hard case

- 类别权重解决频率不均衡，让长尾类在梯度中不被多数类淹没。
- Focal Loss 解决难度不均衡，降低 easy sample 权重，强调边界样本；gamma=2 是默认配置。
- Label Smoothing=0.1 缓解歧义样本过拟合并改善置信度校准，使阈值回退更可信。
- 以 weighted F1 选 checkpoint，连续 3 个 epoch 不提升 early stop；同时应关注各类 recall/F1，而不只看 accuracy。

4.4 动态检索与重排

只对课程、老师、产品功能等检索类意图访问向量库。Filter 先加 intent_word 和 status=1，再把当前实体、上下文实体和画像作为可选召回约束。多个实体用 OR 保召回，再在排序阶段按当前实体×3、上下文×1.5、画像×1.2 做乘法增益；乘法能避免低基础相关性的垃圾结果被固定加分抬高。

五、上下文工程

层	内容	注入方式	原因
FactMemory	稳定、浓缩的长期事实	system context 全量	量少、信息密
EventSummary	历史 Session 摘要	按当前 Query RAG	数量随历史增长，多数不相关
当前 Session 近期轮次	原始 user/assistant 消息	messages 保真	支撑指代与连续对话
当前 Session 早期溢出	超过预算的旧轮次	在线摘要	防 context overflow

- 原实现把全部历史拼成普通字符串，角色信息丢失、token 估算粗糙、成本随轮次线性增长。
- 改为从最新轮向前累加，默认 2000-token 预算、保留近 5 轮，超预算部分用与离线 EventSummary 对齐的 Prompt 压缩。
- Session 另有最多 10 轮与 token 上限的双重防线；tiktoken 不可用时才用字符估算。
- V1 用户画像是离线 per-user JSON，尚非在线 API；EventSummary embedding/RAG 是计划接入条件。

六、关键工程取舍

取舍	为什么	边界
BERT 优先、LLM 回退	确定样本低延迟低成本，歧义样本保质量	需要校准置信度和覆盖率
实体知识外置	新实体更新词典即可生效	词典覆盖不足时退回句式特征/LLM
OR Filter + 乘法重排	先保召回再保精度	权重需离线/在线实验，不能长期手调
可选依赖降级	便于 Demo 移植和故障隔离	能力退化必须显式记录
近期保真 + 历史摘要	兼顾指代精度与 token 成本	摘要可能损失细节，需要 RAG 补充

七、面试高频问答

Q1. 为什么不用纯 LLM 做意图？

建议回答：大量高频 Query 可以被本地模型稳定处理，纯 LLM 增加 7-9s 级 API 延迟、成本和可用性风险；高置信 BERT + 低置信 LLM 能把复杂样本留给更强模型。

- 追问展开：7-9s 和 10-50ms 是文档中的量级/估算，不要说成个人线上压测结论。

Q2. 新增老师为什么可以不重训？

建议回答：训练和推理都把实体替换/标记为统一类型 token，模型学的是 ‘老师实体 + 句式’，实体表更新后 EvidenceCollector 自动识别并加标记，权重无需记住具体名字。

Q3. 实体标注会不会依赖词典？

建议回答：会，所以混合保留约 30% untagged 样本，让未命中词典时仍可依靠句式；低置信再回退 LLM。

Q4. 类别权重、Focal Loss、Label Smoothing 分别解决什么？

建议回答：类别权重解决类频率不均，Focal Loss 解决样本难度不均，Label Smoothing 解决硬标签和过度自信；三者互补但要用消融验证。

Q5. 为什么 weighted F1 仍不够？

建议回答：它仍受大类权重影响，可能掩盖长尾类。线上路由更应看各类 precision/recall、低置信覆盖率、LLM 回退率和业务代价矩阵。

Q6. 阈值 0.85/0.90 怎么定？

建议回答：应在验证集做可靠性图/温度缩放，结合误判成本、LLM 成本与覆盖率选择；图片场景不确定性更高所以阈值更保守。

Q7. 为什么证据收集放在意图前？

建议回答：实体类型本身是强意图特征，能把业务知识从模型权重中外置；先有 evidence 再分类，再用 intent 指导检索。

Q8. 为什么 Filter 用 OR？

建议回答：AND 容易因实体不一致召回为空；OR 先保留老师相关和学科相关候选，再用当前实体/上下文/画像的差异权重重排。

Q9. 为什么用乘法重排？

建议回答：乘法保留基础相关性门槛，低相关结果再多业务 boost 也不容易被抬到顶部；加法可能让垃圾结果靠固定加分越级。

Q10. 上下文为什么不能全量拼接？

建议回答：角色丢失、token 线性增长、旧信息干扰当前意图。分层后近期轮次保真，长期事实全量，历史摘要按需召回，超预算再压缩。

Q11. FactMemory 和 EventSummary 有何不同？

建议回答：FactMemory 是跨 Session 的稳定事实，量少可全量注入；EventSummary 是每次会话摘要，数量大、按 Query 相关性召回。

Q12. 如何评估系统？

建议回答：离线看实体识别、意图 per-class F1/校准、召回 NDCG/Recall@K；在线看回退率、首包、零结果率、搜索成功/点击/转化、多轮承接和成本，并按意图分桶。

Q13. 有什么没有做完？

建议回答：技术资料没有给出完整线上意图准确率和消融结果；V1 画像是离线 JSON，EventSummary 在线向量召回尚是接入规划；Demo 的规则兜底不代表生产。

八、两分钟项目陈述模板

高途 C 端搜索输入很杂，包括老师别名、拼音、产品功能、无实体知识问答和跨轮指代。纯关键词覆盖不足，纯向量难区分意图，纯 LLM 又有成本和时延。我们把链路拆成 Query 标准化、Evidence、Intent、检索路由和 Session 上下文。先通过全半角、繁简、拼音和分词清洗 Query，再用精确、token、模糊等多路证据识别业务实体；BERT 处理高置信样本，低置信回退轻量 LLM。BERT 训练上，我使用真实用户样本与实体增强，让模型学习实体类型而不是名字，并用类别权重、Focal Loss 和 Label Smoothing 处理长尾与 hard case。检索类意图按意图和实体构造动态 Filter，多个条件先 OR 保召回，再对当前 Query 实体、上下文实体和画像做乘法重排。多轮上下文方面，把原先的历史字符串改为 role-aware messages：FactMemory 作为稳定事实全量注入，EventSummary 按需 RAG，当前 Session 近期轮次保真，超预算部分摘要。这样整套方案把确定性、本地模型和 LLM 按成本分层，同时明确 Demo 与生产基础设施的边界。

资料依据与表达边界

边界 旧简历是职责表述的第一依据；技术文档中的性能数字部分是估算/推荐配置，未给出完整线上效果，不应包装成个人实测收益。独立目录是原生产项目的算法 Demo。

主要依据：

- 高途实习材料/阚海_简历_27 应届.pdf（职责与项目名称的第一参考）
- 高途实习材料/TECH_aisearch.md（算法与工程细节的第二参考）
- 高途实习材料/TECH_userprofile.md（长期记忆与上下文联动）