

技术栈八股与项目追问手册

围绕多 Agent、LLM 应用、检索、记忆、多模态与高并发工程，按“核心答案 + 项目映射”组织

适用：大模型应用 / Agent 算法 / 搜索推荐 / Python 后端面试 | 版本：2027 届秋招初稿

使用方法 先掌握 P0 题并能映射到一个真实项目；P1 题用于二面深挖；P2 题用于系统设计。回答顺序统一为：定义 -> 为什么 -> 项目怎么做 -> 边界/改进。

一、准备优先级地图

优先级	主题	必须映射的项目
P0	Session/Topic/Task、Handoff、状态机、CAS/幂等/outbox	阿里 EduBot
P0	Context、Long-term Memory、RAG、token 预算	高途搜索 + 用户画像
P0	BERT、Transformer、Focal Loss、Label Smoothing、阈值	高途智能搜索
P0	HTTP/SSE/WebSocket/gRPC、连接池、超时重试、网关	阿里两项目
P1	Redis、多 Worker、多机房、原子 claim、分布式锁	阿里主动服务
P1	BM25/向量/混合检索/重排	高途智能搜索
P1	多模态、抽帧、ASR、受约束输出	高途多模态标签
P1	A/B、p-value、意向治疗、曝光归因	阿里实验
P2	可观测性、安全隐私、容量与降级系统设计	全部项目

二、多 Agent 与控制面

Q1. Session、Turn、Topic、Task 分别是什么？

建议回答：Session 是连续交互外层容器；Turn 是一次输入到稳定输出；Topic 是语义边界；Task 是某 Agent 对某目标的一次有生命周期执行。混用会导致上下文、状态和恢复对象错位。

- 追问展开：项目映射：阿里项目一期 `topic_id==task_id` 只是简化，目标是 Topic 1:N Task。

Q2. Handoff、Handback、ToolCall/ToolResult 如何配合？

建议回答：Main 用 ToolCall 表达交出任务的意图，Router 创建/恢复 Task 后 dispatch；SubAgent 完成时 Handback，Router 将任务置终态并补配对 ToolResult，再让 Main 收尾。

- 追问展开：项目映射：active 时 ToolCall 暂时未闭合是合法；抢断/完成/过期时必须闭合。

Q3. sticky routing 有什么价值和风险？

建议回答：价值是连续任务绕过 Main，降低时延和抖动；风险是用户换题后错误黏住。需要 Gate 对最新 Query 与 active Task 做连续性判断。

- 追问展开：项目映射：EduBot 用规则优先+小模型，在 Router 最终校验后生效。

Q4. 为什么 Gate 不是 Router？

建议回答：算法建议与状态权威分离，便于 shadow/A-B/校准、开关和并发校验。Router 才能基于 revision/CAS 修改 durable owner。

- 追问展开：项目映射：任何指标都要区分 advice、apply、transition 和 final target。

Q5. checkpoint 和对话摘要有什么不同？

建议回答：摘要是给人/模型看的语义进度；checkpoint 是 Agent 可 restore 的内部执行状态引用。摘要不能恢复工具栈、中间结果或安全点。

- 追问展开：项目映射：阿里一期只有 summary+LGI，无通用 checkpoint。

三、状态机、并发一致性与可靠消息

Q1. CAS/乐观锁解决什么？

建议回答：读取时带 version，提交时要求 `current_version==expected_version`，防旧快照覆盖新状态。适合冲突较少、读多写少的状态。

- 追问展开：项目映射：EduBot PREEMPT/RESUME 使用 revision/CAS；冲突后仍需重评。

Q2. CAS 为什么不能代替幂等？

建议回答：CAS 防并发覆盖，同一个 command 网络重试仍可能在新版本上重复执行。幂等需要 command_id 台账返回第一次结果。

- 追问展开：项目映射：目标台账保存 command、target、precondition、result 和 resulting_version。

Q3. transactional outbox 是什么？

建议回答：业务状态和待投递事件在同一数据库事务写入，worker 再至少一次投递，下游按 idempotency key 去重，避免状态已变但消息未发。

- 追问展开：项目映射：适合 Task 激活后 dispatch、Handback 后 complete 等跨服务窗口。

Q4. exactly-once 能实现吗？

建议回答：端到端通常通过 at-least-once + 幂等效果逼近，而不是依赖网络一次送达。要定义 exactly-once 是消息、状态还是业务副作用。

- 追问展开：项目映射：主动候选当前不是 exactly-once，需要 atomic claim + delivery token。

Q5. 分布式锁与 lease 有什么区别？

建议回答：锁强调互斥，lease 带过期时间和持有者身份，适合崩溃恢复。释放要校验 token，避免旧持有者删掉新锁。

- 追问展开：项目映射：Pending steering claim 应带 request_id/token/deadline。

Q6. 如何处理迟到结果？

建议回答：所有终态带 task_id、command_id、expected_version/epoch；只允许合法 owner 在未 settled 时提交。旧结果记录为 stale，不更新新任务。

- 追问展开：项目映射：同 Agent 不等于同 Task。

四、高并发与 Python 服务

Q1. 线程、进程、协程怎么选？

建议回答：I/O 密集用协程或线程隐藏等待；CPU 密集 Python 受 GIL 影响，优先多进程/原生库/GPU；混合服务常用 async I/O + 独立推理 worker。

- 追问展开：项目映射：高途 EventSummary 外部 LLM I/O 用 ThreadPoolExecutor；ASR 可独立 worker 池。

Q2. 什么是背压？

建议回答：下游处理不过来时，上游必须限速、排队有界、拒绝或降级，避免无限队列拖垮内存和尾延迟。

- 追问展开：项目映射：Event 合并、Session 单飞、队列长度和超时都是主动服务的背压手段。

Q3. 高并发下为什么关注 p99？

建议回答：均值掩盖排队、GC、慢依赖和锁竞争；用户体验和超时通常由尾部决定。应拆连接、排队、模型、SSE、持久化阶段。

- 追问展开：项目映射：Gate 总耗时不能简单等同模型耗时。

Q4. 连接池解决什么？

建议回答：复用 TCP/TLS 连接，降低握手、端口和 CPU 成本；要配置最大连接、keep-alive、获取超时、空闲回收和 DNS。

- 追问展开：项目映射：阿里客户端按 Worker 复用连接。

Q5. 超时、重试、熔断、隔离如何组合？

建议回答：每跳有 deadline；只重试幂等且可恢复错误，指数退避+jitter；持续失败熔断；线程池/连接池隔离慢依赖；总体预算小于上游 deadline。

- 追问展开：项目映射：主动 Gate 超时返回空，不阻断主回答；高途 LLM 只重试网络/408/429/5xx。

Q6. 什么是惊群和请求合并？

建议回答：同一热点 key 失效时大量请求同时回源形成惊群。可用 singleflight、互斥更新、随机 TTL、stale-while-revalidate。

- 追问展开：项目映射：同 Session 短时间重复 Event 可合并。

五、HTTP、SSE、WebSocket、gRPC 与网关

Q1. HTTP keep-alive 和连接池的关系？

建议回答：keep-alive 允许单连接复用，连接池管理多条可复用连接及并发借还。HTTP/2 还能在一条连接上多路复用，但仍需流控和最大并发。

- 追问展开：项目映射：模型/主动服务客户端都应复用连接。

Q2. SSE 与 WebSocket 怎么选？

建议回答：SSE 是服务端到客户端单向、基于 HTTP、自动重连和文本事件，适合 LLM 流式输出；WebSocket 全双工，适合实时交互，但连接治理更复杂。

- 追问展开：项目映射：EduBot Chat/Live 用 SSE 映射不同事件帧。

Q3. SSE 断线续传怎么做？

建议回答：事件带单调 ID，客户端回 Last-Event-ID/LGI，服务端从可重放缓冲继续；要防重复、跳帧和旧请求继续发流。

- 追问展开：项目映射：Task LGI 与 Session 高水位要分开，incoming ACK 只能单调推进。

Q4. gRPC 适合什么？

建议回答：内部强类型 RPC、HTTP/2 多路复用和双向流；不适合浏览器直连的普适性场景。需要处理 deadline、status、负载均衡和 protobuf 兼容。

- 追问展开：项目映射：Agent Adapter 内部服务可考虑 gRPC，外部客户端仍可 SSE。

Q5. API 网关做什么？

建议回答：认证鉴权、路由、限流、灰度、协议转换、熔断、观测和 WAF；不应承载复杂业务状态机。

- 追问展开：项目映射：Router 是业务控制面，不等于 API Gateway。

Q6. 长连接的资源风险？

建议回答：每连接占 fd、内存、缓冲区和心跳；慢客户端会积压发送队列。需要连接上限、idle timeout、写超时、心跳和背压。

- 追问展开：项目映射：Live/SSE 需要处理客户端断开并终止内部生成器。

六、Redis、缓存与多机房

Q1. Cache Aside 怎么工作？

建议回答：读先查缓存，miss 回源并回填；写先更新数据库再删缓存是常见做法，但并发下仍需版本/延迟双删或消息驱动。

- 追问展开：项目映射：主动服务的 pending slot 更像业务状态，不是普通 Cache Aside。

Q2. Redis GETDEL/ Lua/CAS 的差别？

建议回答：GETDEL 原子取删适合一次消费但不支持 judge 后释放；Lua 可原子校验版本并转状态；WATCH/MULTI 是乐观事务，冲突需重试。

- 追问展开：项目映射：steering 需要 CLAIMED lease，Lua 状态机比直接 GETDEL 更合适。

Q3. 缓存穿透、击穿、雪崩？

建议回答：穿透是查不存在 key，可布隆/空值；击穿是热点过期并发回源，可 singleflight；雪崩是大量同时过期，可随机 TTL、分批预热和降级。

- 追问展开：项目映射：用户画像/会话缓存要分别处理不存在与热点。

Q4. 多机房为什么难做到强一致？

建议回答：跨区 RTT 高且网络分区不可避免；同步强一致影响可用性，异步复制有短暂重复/陈旧。要按业务选择主区、revision、幂等和冲突策略。

- 追问展开：项目映射：主动服务后台多写、本地读是时延优先，必须接受短暂副本窗口。

Q5. TTL 只是防内存泄漏吗？

建议回答：还表达业务新鲜度和租约边界。TTL 到期不等于逻辑已处理，关键状态还需终态/审计记录。

- 追问展开：项目映射：pending steering TTL 防陈旧候选，但 Gate 仍需用最新 Query 重判。

七、Transformer、BERT 与分类训练

Q1. Self-Attention 公式与复杂度？

建议回答： $\text{Attention}(Q,K,V)=\text{softmax}(QK^T/\sqrt{d_k})V$ 。序列长度 n 下时间/显存通常 $O(n^2)$ ，多头让模型在不同子空间学习关系。

- 追问展开：项目映射：解释长上下文为何昂贵，也支撑 token 预算设计。

Q2. BERT 与 GPT 的区别？

建议回答： BERT 双向编码、MLM 预训练，适合理解/分类；GPT 自回归 next-token，适合生成。部署意图分类时 BERT 小模型可低延迟。

- 追问展开：项目映射：高途 BERT 做 intent，LLM 处理低置信和回答生成。

Q3. Focal Loss 是什么？

建议回答： $FL=-(1-p_t)^\gamma \log p_t$ ，降低高置信 easy sample 权重，突出 hard case； $\gamma=0$ 退化为 CE。

- 追问展开：项目映射：与 class weight 解决不同维度，需消融。

Q4. Label Smoothing 有什么用？

建议回答： 把 one-hot 目标变为软分布，降低过度自信、提升泛化/校准；过大会伤害可分性。

- 追问展开：项目映射：有助于 confidence threshold 更可信，但不能代替温度校准。

Q5. 类别不平衡怎么处理？

建议回答： 重采样、class weight、Focal、数据增强、阈值按类设置、两阶段分类；评估用 macro/per-class F1 和 PR，而非只看 accuracy。

- 追问展开：项目映射：课程类 33k vs 其他类 26 的极端不平衡要先治理数据。

Q6. 怎么做置信度校准？

建议回答： 验证集画 reliability diagram、计算 ECE/Brier，做 temperature scaling；阈值按误判成本和 LLM 回退预算选。

- 追问展开：项目映射：文本 0.85、图片 0.90 是配置，应通过校准和在线覆盖率验证。

Q7. 实体增强训练为何有效？

建议回答：把具体名字替换/标注为实体类型，模型学习结构信号而非记忆实体；训练推理必须用相同标注逻辑。

- 追问展开：项目映射：高途新增老师只更新 entities.csv。

八、检索、RAG 与重排

Q1. BM25 的核心思想？

建议回答：基于词频、逆文档频率并对文档长度归一化；词频收益会饱和，适合关键词精确匹配。

- 追问展开：项目映射：与向量检索互补。

Q2. 稠密向量检索的优缺点？

建议回答：能召回语义相近表达，但对精确实体、数字和新词可能不稳定；还受 embedding 版本和 ANN 召回误差影响。

- 追问展开：项目映射：高途用业务实体/intent Filter 约束。

Q3. 混合检索怎么融合？

建议回答：可先分别召回，再用加权分数或 RRF 融合；原始分数量纲不同要归一化。之后用 cross-encoder/LLM 或业务特征重排。

- 追问展开：项目映射：文档示例是向量+BM25，再做实体乘法 boost。

Q4. RAG 的完整链路？

建议回答：切分、embedding、索引、Query 改写、召回、过滤/融合、重排、上下文拼装、生成、引用与评估。

- 追问展开：项目映射：EventSummary 多、应按 Query RAG；FactMemory 少、可直接注入。

Q5. chunk 怎么切？

建议回答：按语义/结构优先，大小与 overlap 在召回完整性和噪声/成本之间权衡；表格/对话要保结构和元数据。

- 追问展开：项目映射：EventSummary 天然按 session，是很好的语义块。

Q6. 如何评估 RAG ?

建议回答：分别评 retrieval Recall@K/MRR/NDCG、context precision/recall、answer faithfulness/accuracy 和端到端任务指标；建立无法回答集与引用核验。

- 追问展开：项目映射：不要只看主观回答效果。

Q7. 为什么乘法 boost 可能有风险？

建议回答：多个实体连续相乘可能放大过度且分数失去可比性，需要上限、log-space 或学习排序；Filter OR 也可能扩大噪声。

- 追问展开：项目映射：面试中主动给出离线 NDCG 与在线搜索成功率调参方案。

九、Context Engineering 与长期记忆

Q1. 上下文应该如何分层？

建议回答：system/策略、当前 Query、近期原文轮次、Topic/Task 状态、长期事实、按需召回历史各自有不同优先级和生命周期。

- 追问展开：项目映射：高途近期保真+FactMemory+EventSummary RAG；阿里 Task-scoped context。

Q2. 为什么不能全量历史？

建议回答：成本和时延线性增长，旧信息干扰、隐私暴露、超窗截断不可控。应做预算、最近优先、摘要和检索。

- 追问展开：项目映射：tiktoken 计数优先于字符估算。

Q3. 摘要会丢信息怎么办？

建议回答：原文保留权威存储，摘要带来源和时间；需要细节时 RAG 回源，关键 Task 状态不只存在自然语言摘要里。

- 追问展开：项目映射：summary 不能替 checkpoint。

Q4. 长期记忆如何更新？

建议回答：先提取候选事实，再按类型/标签与旧事实做 ADD/SKIP/MERGE/REPLACE；保留 inactive 历史和来源，处理 TTL、删除与用户纠正。

- 追问展开：项目映射：高途 FactMemory 协议。

Q5. 什么信息不该记？

建议回答：临时闲聊、敏感信息、未经确认推断、短期情绪和无长期价值内容；应按用途、同意、保留期与可删除性治理。

- 追问展开：项目映射：教育未成年人场景尤其严格。

Q6. Prompt injection 如何防？

建议回答：外部内容与系统指令分层，工具/控制信号结构化并白名单，检索内容视为数据，限制工具权限与输出校验。

- 追问展开：项目映射：用户文本不能伪造 Handoff/Handback/steering。

十、多模态、视频与 ASR

Q1. 视频为什么常转成帧+音频文本？

建议回答：便于复用图文 MLLM 接口、控制输入成本，并把视觉和语言证据显式化；代价是时序信息损失。

- 追问展开：项目映射：高途 20 帧+ASR。

Q2. 均匀抽帧与关键帧方法对比？

建议回答：均匀简单稳定但会漏短镜头；镜头切分覆盖场景变化；CLIP/熵/字幕变化可选高信息帧，但计算更贵。

- 追问展开：项目映射：可先均匀基线再做离线消融。

Q3. ASR 常见问题？

建议回答：口音、噪声、专有词、断句、时间戳和幻觉；可用 VAD、热词、语言模型、置信度和字幕/视觉交叉验证。

- 追问展开：项目映射：音频文本在教育视频中常是核心证据。

Q4. 多标签分类怎么评？

建议回答：micro/macro F1、per-label precision/recall、Precision@K、subset accuracy、空标签正确率和标签一致性；类别长尾要分层。

- 追问展开：项目映射：兴趣和地域应分别评估。

Q5. 结构化输出为什么仍需解析/校验？

建议回答：LLM 可能返回非 JSON、自创字段/标签或越界值。要 schema 校验、候选白名单、重试/repair 和业务后验规则。

- 追问展开：项目映射：高途只保留 tag 映射中存在的结果。

十一、可观测性与实验

Q1. Metrics、Logs、Traces 怎么分工？

建议回答：Metrics 看趋势和告警，Logs 解释单事件细节，Trace 串跨服务关键路径。高基数 ID 放日志/Trace，不做 metric label。

- 追问展开：项目映射：EduBot 以 request/session/task/intervention 关联。

Q2. 为什么 HTTP 200 不等于业务成功？

建议回答：它只证明协议请求成功；还要验证配置命中、算法判断、状态 apply、下游执行、最终 responder、客户端接收和持久化。

- 追问展开：项目映射：两个阿里项目都强调分阶段语义验收。

Q3. A/B 的 p-value 表示什么？

建议回答：在零假设下观察到当前或更极端差异的概率，不是‘方案为真的概率’，也不表示效果大小。要同时报告 uplift、置信区间与业务意义。

- 追问展开：项目映射：主动服务 $p \leq 0.0096$ 说明差异显著，但仍需归因口径。

Q4. 意向治疗与实际曝光分析区别？

建议回答：ITT 按分桶比较，保留随机化但会被低曝光稀释；treated-only 按实际曝光可能有选择偏差。可用触发资格、工具变量或受控曝光设计。

- 追问展开：项目映射：主动服务只有 2.57% 实际注入，不能直接把 ITT lift 当单次注入效应。

Q5. 多指标实验如何防误判？

建议回答：预注册主指标和 guardrail，控制多重比较，检查样本比例失衡、随机化、时序、机器人/拨测流量和新奇效应。

- 追问展开：项目映射：路由单日 1128/197 样本应谨慎。

Q6. 如何设计审计抽样？

建议回答：链路健康度尽量全量；语义质量按关键分支定向覆盖，再补随机样本估总体。异常逐个下钻，所有结论保留分母和边界。

- 追问展开：项目映射：阿里审计先 902 请求全量，再 18 Session 定向语义。

十二、安全、隐私与降级

Q1. fail-open 和 fail-closed 怎么选？

建议回答：核心业务可用性和附加能力风险分别判断。主回答可以 fail-open 继续，主动干预应 fail-closed 不展示未经确认内容。

- 追问展开：项目映射：Handoff Gate 已知 active 时继续；Proactive 异常返回空。

Q2. 最小权限如何落地？

建议回答：服务/工具只获取完成任务所需数据和动作，凭据独立、短期、可轮换；用户/Session/Task 关联要鉴权，日志脱敏。

- 追问展开：项目映射：Agent 工具白名单和 Task-scoped context。

Q3. 如何治理未成年人数据？

建议回答：用途限制、最小化、敏感字段隔离、短保留期、访问审计、可删除/纠正，避免用情绪或健康信息做不必要推荐。

- 追问展开：项目映射：主动服务的画像/情绪处理风险更高。

Q4. 降级为什么要分类？

建议回答：disabled、skip、miss、timeout、error、stale、conflict、delivered 的业务含义不同；混在一起会掩盖依赖故障或误判。

- 追问展开：项目映射：每次 fallback 都要有 reason。

Q5. 如何防内部控制协议被用户伪造？

建议回答：控制消息使用结构化类型、签名/来源标识、白名单字段和服务端生成 ID；用户文本永远按数据处理，不能直接改变 owner 或 Task 状态。

- 追问展开：项目映射：Handoff/Handback/steering 不接受自然语言伪造。

十三、系统设计题答题模板

1. 先问清规模与 SLA：QPS、并发连接、消息长度、首 token/p99、可用性、数据新鲜度、是否允许重复。
2. 定义业务身份和不变量：request/session/topic/task/intervention；谁是 owner；什么必须单调或只能一次。
3. 画主链和异步链：入口/网关 -> 控制面 -> 执行面 -> 存储/缓存 -> 流式交付 -> 观测。
4. 分读写路径与状态：权威存储、缓存、版本、TTL、幂等键、outbox、重试和补偿。
5. 做容量估算：峰值 QPS、连接数、消息大小、缓存/日志量、模型吞吐和并发预算。
6. 设计失败语义：每个依赖超时后回什么、状态是否提交、是否释放 claim、是否允许重试。
7. 说明观测与实验：阶段事件、p50/p95/p99、质量指标、业务指标、guardrail、灰度和回滚。
8. 最后主动讲边界：一期简化、未完成能力、P0 风险和演进顺序。

十四、14 天复习节奏

天	主题	验收
1-2	阿里 Router/Task 项目 + 状态机	能白板画五动作，2 分钟讲清 advice/effect
3	CAS/幂等/outbox/lease	用四个故障窗口解释各机制
4	SSE/连接池/超时重试/背压	完成一个 LLM 流式服务系统设计

天	主题	验收
5-6	高途搜索 + BERT	手写 Attention/Focal，讲清实体增强和阈值
7	BM25/向量/RAG/重排	能设计离线+在线评估
8	用户画像与长期记忆	讲清三层记忆、merge、TTL、隐私
9	多模态标签/ASR/抽帧	讲清消融、评价指标和工程降级
10	主动服务	画 prepare-confirm、L0-L4、atomic claim
11	A/B 与可观测性	正确解释 p-value、ITT、2.57% 注入
12	简历逐条反问	每个数字能说来源、口径、边界
13	模拟一面	项目 2 分钟 + 每个项目 10 个追问
14	模拟二面/系统设计	45 分钟完成设计并复盘取舍

十五、最后的表达红线

- 不把目标设计说成已上线；不把 Demo 说成完整生产系统。
- 不把估算时延说成个人压测；不为高途项目补不存在的准确率/收益。
- 不隐去样本量、时间窗口、实际干预率和抽样方式。
- 不把 HTTP 200、Gate hit、缓存命中当用户效果。
- 回答技术债时先承认事实，再说影响、定位证据和改进顺序。
- 所有项目至少准备：30 秒版本、2 分钟版本、架构图、一个难点、一个故障、一个权衡、一个未完成边界。

资料依据与表达边界

边界 本手册按你的项目反向组织八股；定义性内容可作为知识储备，涉及项目状态和数字时仍以对应项目文档的证据边界为准。

主要依据：

- 高途实习材料/阚海_简历_27 应届.pdf
- 高途实习材料/TECH_aisearch.md
- 高途实习材料/TECH_userprofile.md
- 高途实习材料/tagdoc.md

- 阿里实习材料/01-路由与 Handoff 完整业务逻辑.md
- 阿里实习材料/02-任务编排与 Topic 完整设计.md
- 阿里实习材料/03-主动服务完整业务与算法设计.md
- 阿里实习材料/04-统一架构与链路工程设计.md
- 阿里实习材料/edubot-on-bucket-audit-2026-08-26.md
- 阿里实习材料/各类实验收益.txt 与主动服务实验截图