

多模态标签服务

图文/视频统一媒体编排 + 候选约束的 MLLM 决策 + 本地规则纠偏

公司：高途教育集团 | 角色：负责人 | 时间：2026.02 - 2026.04 | 文档形态：生产主链抽取后的独立 Demo

30 秒版本 我负责教育内容发布后的兴趣和地域标签主链。图文侧做图片读取、压缩和多图编排；视频侧做均匀抽 20 帧、封面优先、16k 音频转写，再转成多帧图片+文本给多模态模型。模型不能自由造标签，只能从候选集合里选，并参考定义和正负样例；返回后还要经过白名单映射、必含/排除词、优先级覆盖、去重和 Top3。工程上做了 Provider 抽象、ASR 懒加载与串行锁、单媒体失败不中断。

一、业务问题

内容发布后需要抽取兴趣标签和地域标签，供上游系统消费和下游分发。兴趣标签描述主题，如物理、中考、地方教育通知；地域标签不是普通 NER，而是判断最应该接收内容的用户当前所在地。输入既有图文也有视频，信息可能分布在标题、封面、正文帧和音频中。

难点	为什么难	对应方案
多模态异构	图片、视频时序、封面、音频证据强弱不同	统一媒体编排，视频转多帧+ASR 文本
标签体系受控	模型容易自创或按字面过度泛化	候选、定义、正负样例 + 返回白名单
业务语义特殊	地域标签不是提到哪个地名	Prompt 明确目标受众地域，普通提及返回空
工程依赖重	cv2/moviepy/FunASR/LLM 网关	懒加载、provider 抽象、可降级 Demo

二、我的工作

- 负责 PostTagAnalyzer 媒体编排：图文/视频分流、本地/远程读取、图片 resize/base64、视频临时文件与清理。
- 实现视频均匀抽 20 帧、末帧补齐、封面插到 frames[0]、16k WAV 导出与 FunASR 转写。
- 组织兴趣/地域候选标签，拍平地域树并去重，构造图文/视频差异化 Prompt 和 OpenAI-compatible 多模态 messages。
- 实现 LLM JSON 解析、tagNumber/tagDefine 映射、必含/排除词、优先级覆盖、去重和最多 3 标签。

- 抽象 MockHeuristic / OpenAICompatible Provider, 做 ASR 懒加载、audio_lock 和单图片失败不中断。

三、端到端链路

3.1 图文

```
image_urls + image_paths
-> 逐张读取 -> cv2 解码 -> 宽度 > 800 等比缩放
-> JPEG + base64 -> 标题/正文 + 候选标签 + 定义/样例
-> 多模态 LLM -> JSON -> 白名单映射 -> 规则过滤 -> tags/regionTags
```

3.2 视频

```
video_url/path -> 远程下载或本地直读 -> moviepy duration/fps
-> 按总帧数均匀抽 20 帧 -> resize/JPEG/base64 -> 封面插入首位
-> 有音轨且 enable_asr: 导出 16k WAV -> FunASR -> transcript
-> 标题 + transcript (核心) + frames (辅助) -> MLLM -> 规则后处理
```

四、算法设计

4.1 为什么视频抽 20 帧

按总帧数均匀采样能对不同长度视频保持固定成本，并补最后一帧提高尾部覆盖。20 不是理论最优，只是信息量、传输/token 成本和实现复杂度的工程折中；缺点是无时序语义、可能错过关键镜头，后续可用镜头切分或关键帧评分优化。

4.2 为什么封面优先

教育短视频的封面通常浓缩标题与主题。把封面置于第一张可让模型先看到高信息密度证据，但也可能受到标题党影响，因此正文帧和 ASR 文本仍需交叉验证。

4.3 受约束标签选择

- Prompt 给候选标签列表，不允许模型自由生成；标签定义防止只按字面理解。
- 正负样例明确边界，例如‘细胞分裂过程详解’可选生物，‘数学家的故事’不等于数学课程内容。
- 地域标签判断目标受众所在地，提到地点但没有定向分发语义时返回空。
- 解析阶段只保留候选映射中存在的标签，阻断自创和格式污染。

4.4 为什么模型后还要规则

Prompt 无法完全保证业务边界。后验规则对学科、生态环境、竞赛活动、地方教育通知等重点标签做必含/排除词和优先级压制；之后去重并限制 Top3。它不是完全规则化，而是让模型负责复杂理解、规则负责高风险边界。

五、工程设计

设计	收益	代价/边界
图片压到 800 宽	降低带宽和视觉 token	小字可能损失，需按 OCR/内容类型评估
单张图失败继续	部分容错，不因坏图丢整帖	需要记录有效图片数与降级原因
ASR 懒加载	图文路径不加载重模型	首次视频请求有冷启动
audio_lock	规避模型线程安全/显存竞争	视频 ASR 并发被串行化
Mock Provider	无网关也能跑通结构	不看视觉内容，不能代表真实效果
OpenAI-compatible	便于切模型/网关	依赖外部服务和 API key

六、已知问题与改进

技术债	影响	改进
needHidden 地域未过滤	隐藏候选可能进 Prompt	候选构建阶段过滤并加单测
标签源本身有噪声	模型选择空间受污染	标签数据治理、版本与质量校验
keywords/word_freq 未进决策	有计算但无收益	进入 Prompt 或规则并做消融
mock 不看图	只能证明链路，不能证明效果	明确标注能力边界或构造可解释视觉 stub
stream=True 与 requests 非流式混用	协议语义不一致	统一真实/非流式客户端合同
Demo 未标准打包	CI/迁移不规范	pyproject.toml + wheel + 依赖 extra
均匀抽帧无时序	漏关键镜头	shot boundary / CLIP 关键帧 / ASR 时间对齐

七、面试高频问答

Q1. 为什么不是直接把视频传给模型？

建议回答：固定抽帧+ASR 能控制成本、兼容图片消息接口，也让证据可观测；直接视频理解依赖模型能力和更高资源。

Q2. 20 帧怎么定的？

建议回答：它是工程折中，不是最优常数。应通过长短视频分层、标签离线集和成本曲线比较 8/12/20/32 帧，观察 F1/一致性与 token/时延。

Q3. 均匀抽帧有什么问题？

建议回答：没有镜头边界和时序意识，可能漏掉短暂关键画面。可用场景切分、CLIP 相似度去冗余、信息熵/字幕变化选帧，并与 ASR 时间戳对齐。

Q4. 为什么视频 Prompt 更重视音频？

建议回答：教育视频核心知识往往在讲解语音中，画面可能只是板书或素材；图文则标题和图片更关键。权重是业务先验，仍要用消融验证。

Q5. 地域标签为什么不是 NER？

建议回答：NER 只识别内容提到的地点，分发需要判断最适合接收者所在地。‘介绍北京历史’未必只投北京，而‘北京市中考报名通知’具有明确地域定向。

Q6. 为什么候选约束重要？

建议回答：可阻断模型自创标签，保证输出能映射到线上 tagName/tagDefine，也让评估空间固定、便于版本治理。

Q7. 规则会不会越来越多？

建议回答：会，因此只治理高风险/高频边界，规则要有版本、命中率和误杀率；低风险长尾仍交模型，定期用错误集决定增删。

Q8. 为什么需要 Provider 抽象？

建议回答：把媒体编排和标签决策接口解耦，支持离线 mock、真实网关和后续模型切换；还能分别测试链路正确性和模型质量。

Q9. audio_lock 的取舍？

建议回答：锁换取模型线程安全和资源稳定，但吞吐受限。生产可用独立 ASR 服务、GPU worker 池、队列 + 批处理或每进程模型副本。

Q10. 如何评估？

建议回答：构造多标签人工集，兴趣/地域分别看 micro/macro F1、precision@3、空标签准确率、一致性；视频做标题/封面/帧/ASR 消融，并统计时延、token、失败和降级率。

Q11. 单图失败为什么不中断？

建议回答：帖子可能有多张图，坏一张不应丢弃其余有效证据。返回时需记录有效输入数，全部失败再走纯文本或空结果。

Q12. Demo 和原服务差别？

建议回答：Demo 移除了 HTTP、Apollo、远端标签拉取、回调和部署，只保留真实算法主链；所以可以讲算法设计，但不能拿 Demo 运行等同生产 SLA。

八、两分钟项目陈述模板

这个项目为教育图文和视频内容抽取兴趣与地域标签。难点一是多模态证据分散，难点二是线上标签体系受控，难点三是地域标签并不等于地名识别。我负责媒体编排和标签决策主链：图文逐张读取并压到 800 宽、编码为多模态消息；视频按总帧数均匀抽 20 帧，补末帧，封面放第一位，有音轨时导出 16k WAV 用 FunASR 转写。模型输入里带候选标签、定义和正负样例，只能从候选集合选择；返回后只保留可映射 tagName 的结果，再做必含/排除词、优先级覆盖、去重和 Top3。工程上用 Provider 抽象支持 mock 和 OpenAI-compatible，ASR 懒加载避免图文启动重依赖，audio_lock 换取模型线程安全，单张图失败不中断整帖。复盘明确了隐藏地域未过滤、标签源噪声、关键词没有真正进入决策、均匀抽帧无时序等问题。面试时我会强调当前文档是从原生产服务抽出的算法 Demo，不把它当完整生产系统。

资料依据与表达边界

边界 可说负责生产项目中的算法主链，并将其独立为 Demo；不可说 Demo 自身包含 HTTP/Apollo/回调或证明了真实多模态效果。资料未提供准确率、时延或线上收益，不新增数字。

主要依据：

高途实习材料/阚海_简历_27 应届.pdf（职责与项目名称的第一参考）；高途实习材料/tagdoc.md（算法主链、工程设计与技术债）